

Taller — Limpieza y Análisis de Datos con Pandas y NumPy

Objetivo

Aplicar técnicas de limpieza, transformación y análisis de datos utilizando las librerías Pandas y NumPy a partir de una base de datos con inconsistencias similares a escenarios reales.

Archivos entregados

ventas_sucias_5000.csv

Instrucciones generales

- Trabajar en un notebook de Jupyter (.ipynb) o script .py
 - El código debe estar comentado y organizado
 - Cada respuesta debe incluir:
 - Código
 - Explicación breve del resultado obtenido
 - Justificar decisiones de limpieza cuando sea necesario
-

Parte 1 — Exploración de datos (Pandas)

Actividades

Cargar la base de datos

Mostrar:

- Primeras filas
- Información general del dataset
- Resumen estadístico
-

Debes responder:

¿Cuántas filas y columnas tiene la base de datos?

¿Qué tipos de datos identificas?

¿Encuentras columnas con problemas o inconsistencias?

Parte 2 — Limpieza de datos (Pandas)

Realiza las siguientes tareas:

- Corregir tipos de datos incorrectos
- Identificar y manejar valores nulos
- Estandarizar columnas de texto:
- País
- Método de pago
- Revisar posibles valores atípicos (outliers)
- Corregir formatos de fecha si es necesario

Debes responder:

¿Qué problemas encontraste?

¿Cómo los solucionaste?

¿Eliminaste registros? ¿Por qué?

Parte 3 — Análisis con Pandas

Actividades

- Crear una nueva columna llamada total: `df['total'] = df['precio'] * df['cantidad']`

Obtener:

- Total vendido
- Promedio de ventas
- Venta máxima
- Venta mínima
-

Identificar:

Los 5 productos con mayor valor vendido

El país con más ventas

Parte 4 — Introducción a NumPy

Actividades

- Convertir columnas numéricas a un array de NumPy: `data = df[['precio', 'cantidad']].to_numpy()`
 - Separar columnas utilizando indexación: `precios = data[:, 0]`
`cantidades = data[:, 1]`
 - Aplicar vectorización para calcular ventas totales: `totales = precios * cantidades`
-

Parte 5 — Análisis con NumPy

Utilizando funciones de NumPy, calcular:

- Suma total de ventas
- Promedio de ventas
- Venta máxima
- Cantidad de ventas superiores a 1000
-

Debes responder:

¿Qué ventajas observas al usar NumPy?

¿Qué significa “vectorización”?

¿Qué hace la expresión `data[:, 0]`?

Parte 6 — Interpretación de resultados

Analiza y responde:

¿Los resultados obtenidos tienen sentido?

¿Detectaste valores sospechosos?

¿El promedio representa correctamente los datos?

¿Qué decisiones tomarías si esta fuera información real de negocio?